

Universidade Estadual de Campinas

ME623 - Planejamento e Pesquisa
Professor: Aluísio De Souza Pinheiro

Aplicação de Experimentos Fatoriais Fracionários 2^k para identificação de fatores relevantes na qualidade do vinho

Projeto 2: Análise de Dados

Autora: Amanda Rehder Cedro

IMECC - Instituto de Matemática, Estatística e Computação Científica
UNICAMP – Campinas – SP
2026

Sumário

1 Introdução **4**

2 Metodologia **5**
2.1 Base de dados . . . 5
2.2 Ferramentas computacionais . . . 6
2.3 Seleção das variáveis . . . 6
2.4 Planejamento fatorial fracionário . . . 7
2.5 Codificação dos fatores . . . 8
2.6 Análise exploratória dos dados . . . 8
2.7 Ajuste do modelo estatístico . . . 9
2.8 Avaliação da significância dos efeitos . . . 9
2.9 Diagnóstico do modelo . . . 10

3 Resultados **11**
3.1 Caracterização do Banco de Dados . . . 11
3.1.1 Distribuição da variável resposta . . . 12
3.1.2 Qualidade segundo o tipo de vinho . . . 13
3.1.3 Distribuição do teor alcoólico por tipo de vinho . . . 14
3.1.4 Comparação das variáveis físico-químicas entre os tipos de vinho . . . 15
3.2 Análise das Relações entre Variáveis . . . 16
3.2.1 Matriz de Correlação . . . 16
3.2.2 Mapa de Calor das Correlações . . . 17
3.2.3 Qualidade versus Teor Alcoólico . . . 18
3.2.4 Qualidade versus Acidez Volátil . . . 19
3.2.5 Matriz de Dispersão . . . 20
3.2.6 Síntese da Análise Relacional . . . 21
3.3 Planejamento Fatorial Fracionário . . . 21
3.3.1 Matriz do Delineamento Experimental . . . 21
3.3.2 Características do Planejamento . . . 22
3.3.3 Estrutura de Confundimento . . . 23
3.3.4 Considerações Finais . . . 23
3.4 Análise dos Efeitos . . . 24
3.4.1 Modelo de Regressão dos Efeitos . . . 25
3.4.2 Análise de Variância dos Efeitos . . . 26
3.4.3 Influência do Tipo de Vinho . . . 26
3.4.4 Interação entre Tipo de Vinho e Teor Alcoólico . . . 27
3.4.5 Síntese dos Resultados . . . 27
3.5 Diagnóstico do Modelo . . . 28
3.5.1 Análise gráfica dos resíduos . . . 28
3.5.2 Teste de normalidade . . . 30
3.5.3 Teste de homocedasticidade . . . 30
3.5.4 Autocorrelação dos resíduos . . . 31
3.5.5 Análise de observações influentes . . . 31
3.5.6 Conclusão do diagnóstico . . . 32

4 Discussão Crítica **33**

5 Conclusão 34

Lista de Figuras

1 Distribuição da qualidade dos vinhos presentes no conjunto de dados. . . . 12
2 Distribuição da qualidade segundo o tipo de vinho. 13
3 Distribuição do teor alcoólico segundo o tipo de vinho. 14
4 Distribuição das variáveis físico-químicas segundo o tipo de vinho. 15
5 Mapa de calor da matriz de correlação das variáveis. 17
6 Relação entre teor alcoólico e qualidade do vinho. 18
7 Relação entre acidez volátil e qualidade do vinho. 19
8 Matriz de dispersão entre as principais variáveis do estudo. 20
9 Diagrama de Pareto dos efeitos estimados. 24
10 Interação entre teor alcoólico e tipo de vinho para a qualidade média. . . . 27
11 Resíduos versus valores ajustados. 28
12 Histograma dos resíduos do modelo. 29
13 Gráfico Q-Q dos resíduos. 29
14 Distância de Cook para identificação de observações influentes. 31

Lista de Tabelas

1 Variáveis disponíveis no conjunto de dados Wine Quality 5
2 Codificação dos fatores utilizados 8
3 Frequência absoluta da variável categórica do tipo de vinho 11
4 Estatísticas descritivas das variáveis numéricas do conjunto de dados . . . 11
5 Estatísticas descritivas completas das variáveis numéricas 11
6 Matriz de correlação entre as variáveis numéricas 16
7 Matriz do delineamento experimental fatorial fracionário 2^{7-3} 22
8 Características gerais do planejamento experimental 22
9 Estrutura de confundimento para interações de dois fatores 23
10 Coeficientes e estatísticas de ajuste do modelo de regressão linear 25
11 Tabela da Análise de Variância (ANOVA) para o modelo de qualidade . . . 26
12 Resultados do Teste t de Welch (Qualidade por Tipo de Vinho) 26
13 Análise de Variância (ANOVA) para Qualidade em função do Tipo de Vinho 27
14 Teste de Normalidade de Shapiro-Wilk para os Resíduos do Modelo 30
15 Teste de Breusch-Pagan (Estudentizado) para Homocedasticidade 30
16 Teste de Durbin-Watson para Autocorrelação dos Resíduos 31

1 Introdução

A qualidade do vinho é resultado de processos físico-químicos complexos que envolvem a interação entre diversos fatores, tais como teor alcoólico, acidez, densidade, pH e concentração de compostos específicos. A compreensão da influência dessas variáveis é de grande interesse tanto científico quanto industrial, uma vez que possibilita melhorias no processo produtivo, padronização do produto final e otimização de características sensoriais associadas à aceitação do consumidor.

Tradicionalmente, a avaliação da qualidade do vinho é realizada por especialistas por meio de análises sensoriais. Embora amplamente utilizadas, essas avaliações apresentam limitações importantes, como elevado custo operacional, subjetividade inerente ao processo e dificuldades relacionadas à reprodutibilidade dos resultados. Nesse contexto, o desenvolvimento de métodos estatísticos capazes de identificar fatores relevantes a partir de propriedades mensuráveis torna-se uma alternativa promissora.

Com o avanço das técnicas de análise de dados e o aumento da disponibilidade de bases públicas, tornou-se possível utilizar métodos quantitativos para investigar relações entre características físico-químicas e qualidade percebida do produto. Entre essas bases destaca-se o conjunto de dados *Wine Quality*, disponibilizado pelo UCI Machine Learning Repository [3]. O banco contém informações referentes a vinhos portugueses tintos e brancos, incluindo variáveis físico-químicas e avaliações de qualidade atribuídas por especialistas.

Do ponto de vista estatístico, problemas envolvendo múltiplos fatores podem tornar-se rapidamente complexos devido ao grande número de combinações possíveis entre variáveis e potenciais interações. Em situações desse tipo, técnicas clássicas de Planejamento de Experimentos desempenham papel fundamental ao permitir investigação sistemática dos efeitos dos fatores sobre uma variável resposta.

Entre os métodos de Planejamento Experimental, experimentos fatoriais destacam-se pela capacidade de estudar simultaneamente diversos fatores e identificar tanto efeitos principais quanto possíveis interações. Entretanto, em cenários envolvendo muitos fatores, experimentos fatoriais completos podem exigir número excessivamente elevado de corridas experimentais.

Uma alternativa eficiente consiste na utilização de experimentos fatoriais fracionários. Essa metodologia permite reduzir significativamente o número de experimentos necessários, preservando a capacidade de identificar fatores potencialmente relevantes. A redução ocorre por meio da seleção estratégica de uma fração do experimento completo, assumindo que efeitos de ordem elevada possuem influência desprezível.

Embora o banco utilizado neste estudo não tenha sido originalmente construído sob um planejamento experimental controlado e seja formado por algumas variáveis discretas, a estrutura dos dados permite adaptação para uma abordagem inspirada em experimentos fatoriais. Mediante codificação apropriada das variáveis, torna-se possível investigar efeitos e interações utilizando conceitos clássicos de planejamento experimental.

Dessa forma, o objetivo principal deste trabalho consiste em aplicar conceitos de Planejamento de Experimentos, com ênfase em experimentos fatoriais fracionários 2^k, para identificar fatores associados à qualidade do vinho. Além disso, busca-se ajustar modelos estatísticos, avaliar seus pressupostos teóricos e interpretar os efeitos mais relevantes envolvidos no processo.

2 Metodologia

2.1 Base de dados

O presente estudo foi desenvolvido utilizando o conjunto de dados *Wine Quality*, disponibilizado pelo UCI Machine Learning Repository [3]. O banco foi originalmente apresentado por Cortez et al. (2009) com o objetivo de investigar relações entre propriedades físico-químicas e qualidade sensorial de vinhos portugueses.

A base é composta por dois conjuntos independentes, referentes a vinhos tintos (*red wine*) e vinhos brancos (*white wine*). Cada observação corresponde a uma amostra individual de vinho e contém informações referentes a propriedades físico-químicas obtidas em laboratório, além de uma avaliação de qualidade realizada por especialistas.

O banco original contém as seguintes variáveis:

Tabela 1: Variáveis disponíveis no conjunto de dados Wine Quality

Variável	Descrição
fixed acidity	Acidez fixa
volatile acidity	Acidez volátil
citric acid	Ácido cítrico
residual sugar	Açúcar residual
chlorides	Cloretos
free sulfur dioxide	Dióxido de enxofre livre
total sulfur dioxide	Dióxido de enxofre total
density	Densidade
pH	Potencial hidrogeniônico
sulphates	Sulfatos
alcohol	Teor alcoólico
quality	Qualidade do vinho

A variável resposta utilizada neste estudo foi a qualidade do vinho (*quality*), representada por notas inteiras atribuídas por avaliadores especializados.

Inicialmente os bancos referentes aos vinhos tintos e brancos foram importados para o ambiente computacional. Em seguida, ambos foram integrados em um único conjunto de dados, sendo criada uma variável categórica denominada *wine_type*, responsável por identificar o tipo do vinho analisado.

Após a integração das bases realizou-se a padronização dos nomes das variáveis e a verificação da existência de valores ausentes. A quantidade de dados faltantes foi avaliada por meio da expressão:

$$\sum I(X_i = NA)$$

onde $I(\cdot)$ representa a função indicadora.

Não foram identificados valores ausentes em nenhuma variável, tornando desnecessária a aplicação de procedimentos de imputação ou exclusão de observações.

2.2 Ferramentas computacionais

Todas as análises foram realizadas utilizando a linguagem R.
Os principais pacotes empregados foram:

- ggplot2;
- tidyverse;
- dplyr;
- janitor;
- psych;
- GGally;
- corrplot;
- FrF2;
- car;
- reshape2;
- skimr;
- lmtest;
- qcc.

O pacote `FrF2` foi utilizado para construção do planejamento fatorial fracionário 2^k. Os pacotes `car` e `lmtest` foram empregados para os diagnósticos do modelo estatístico. Os demais pacotes foram utilizados para manipulação dos dados, análise exploratória e construção dos gráficos.

2.3 Seleção das variáveis

O objetivo do estudo consistiu em investigar fatores físico-químicos potencialmente associados à qualidade do vinho.
Foram selecionadas as variáveis:

- teor alcoólico;
- acidez volátil;
- sulfatos;
- densidade;
- pH;
- ácido cítrico;

- tipo do vinho.

A escolha dessas variáveis foi baseada em sua relevância enológica descrita na literatura especializada e em sua disponibilidade no conjunto de dados.

A variável resposta adotada foi:

$$Y = \text{Qualidade}$$

2.4 Planejamento fatorial fracionário

O Planejamento de Experimentos constitui uma metodologia estatística destinada ao estudo sistemático da influência de fatores sobre uma variável resposta.

Em um experimento fatorial completo com (k) fatores avaliados em dois níveis, o número de combinações experimentais é dado por:

$$2^k$$

Nesse tipo de planejamento, todos os fatores são avaliados simultaneamente, permitindo estimar efeitos principais e interações.

Neste estudo foram considerados sete fatores. Assim, um planejamento completo exigiria:

$$2^7 = 128$$

corridas experimentais.

Entretanto, um dos princípios fundamentais dos experimentos fatoriais estabelece que interações de ordem elevada geralmente possuem pequena relevância prática. Dessa forma, pode-se utilizar apenas uma fração do experimento completo sem perda substancial de informação.

Esse procedimento caracteriza um experimento fatorial fracionário.

Foi adotado um planejamento:

$$2^{7-3}$$

resultando em:

$$2^4 = 16$$

corridas experimentais.

A economia experimental obtida foi:

$$\frac{128 - 16}{128} \times 100 = 87,5\%$$

As relações geradoras utilizadas foram:

$$E = ABC$$
$$F = BCD$$
$$G = ACD$$

Essas relações definem a estrutura de confundimento do planejamento, produzindo alisamento entre determinados efeitos e permitindo redução substancial do número de corridas necessárias.

2.5 Codificação dos fatores

Como as variáveis originais utilizadas são em sua grande maioria contínuas, foi necessária sua transformação em fatores binários compatíveis com o planejamento 2^k.

A codificação foi realizada utilizando a mediana de cada variável como ponto de corte. Para cada observação:

$$X = \begin{cases} +1, & X > \text{mediana} \\ -1, & X \leq \text{mediana} \end{cases}$$

A utilização da mediana foi motivada por sua robustez frente à presença de valores extremos.

A codificação dos fatores foi definida conforme a Tabela 2.

Tabela 2: Codificação dos fatores utilizados

Fator	Variável
A	Álcool
B	Acidez volátil
C	Sulfatos
D	Densidade
E	pH
F	Ácido cítrico
G	Tipo do vinho

Para o fator (G), correspondente ao tipo do vinho, utilizou-se:

$$G = \begin{cases} +1, & \text{vinho branco} \\ -1, & \text{vinho tinto} \end{cases}$$

2.6 Análise exploratória dos dados

Antes do ajuste do modelo foi realizada análise exploratória com o objetivo de compreender o comportamento das variáveis e identificar padrões preliminares.

Foram construídos os seguintes gráficos:

- histograma da variável qualidade;
- boxplot da qualidade por tipo de vinho;
- histogramas do teor alcoólico por tipo de vinho;
- boxplots das variáveis físico-químicas;
- gráficos de dispersão entre álcool e qualidade;
- gráficos de dispersão entre acidez volátil e qualidade;
- matriz de dispersão entre variáveis selecionadas;
- matriz de correlação.

A correlação linear foi calculada através do coeficiente de Pearson:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

Valores próximos de 1 indicam associação linear positiva, enquanto valores próximos de -1 indicam associação linear negativa.

2.7 Ajuste do modelo estatístico

Para quantificar a influência dos fatores sobre a qualidade foi ajustado um modelo de regressão linear.

A forma geral do modelo utilizado foi:

$$Y = \beta_0 + \beta_1 A + \beta_2 B + \beta_3 C + \beta_4 D + \beta_5 E + \beta_6 F + \beta_7 G + \beta_8 (A:G) + \beta_9 (B:G) + \beta_{10} (C:G) + \varepsilon$$

em que:

- Y : representa a qualidade do vinho;
- $A, \ldots, G$: representam os fatores codificados;
- ε : representa o erro aleatório.

Os parâmetros foram estimados pelo método dos mínimos quadrados ordinários.
A solução analítica é dada por:

$$\hat{\beta} = (X'X)^{-1}X'Y$$

que minimiza a soma dos quadrados dos resíduos:

$$S(\beta) = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

2.8 Avaliação da significância dos efeitos

A significância global do modelo foi avaliada por meio da análise de variância (ANOVA).
Foram consideradas as hipóteses:

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0$$

$$H_1 : \exists \beta_j \neq 0$$

A estatística utilizada foi:

$$F = \frac{QM_R}{QM_E}$$

onde QM_R representa o quadrado médio da regressão e QM_E representa o quadrado médio residual.

Adicionalmente, os coeficientes individuais foram avaliados através dos testes t de Student.

Também foi realizado um teste t para comparação das médias de qualidade entre vinhos tintos e brancos.

2.9 Diagnóstico do modelo

Após o ajuste do modelo foram avaliados os pressupostos clássicos da regressão linear.

A normalidade dos resíduos foi investigada por meio de histogramas, gráfico Q-Q e teste de Shapiro-Wilk.

As hipóteses consideradas foram:

H_0: os resíduos seguem distribuição normal

H_1: os resíduos não seguem distribuição normal

A homocedasticidade foi avaliada através do teste de Breusch-Pagan.

As hipóteses foram:

$H_0 : Var(\varepsilon_i) = \sigma^2$

$H_1 : Var(\varepsilon_i) \neq \sigma^2$

Além do teste formal, foi construído o gráfico de resíduos versus valores ajustados.

A presença de multicolinearidade foi investigada através do Fator de Inflação da Variância (VIF), calculado por:

$$VIF_j = \frac{1}{1 - R_j^2}$$

em que R_j^2 corresponde ao coeficiente de determinação obtido ao regredir a variável (j) sobre as demais variáveis explicativas.

Por fim, observações potencialmente influentes foram identificadas através da distância de Cook:

$$D_i = \frac{e_i^2}{p\hat{\sigma}^2}\left(\frac{h_{ii}}{(1-h_{ii})^2}\right)$$

sendo adotado como critério de referência:

$$D_i > \frac{4}{n}$$

para classificação de observações potencialmente influentes.

3 Resultados

3.1 Caracterização do Banco de Dados

Antes da construção do planejamento experimental e do ajuste dos modelos estatísticos, realizou-se uma análise exploratória dos dados com o objetivo de compreender a distribuição das observações, identificar padrões gerais das variáveis estudadas e verificar diferenças estruturais entre os vinhos tintos e brancos.

Tabela 3: Frequência absoluta da variável categórica do tipo de vinho

Tipo do Vinho	Frequência
Tinto	1599
Branco	4898

Tabela 4: Estatísticas descritivas das variáveis numéricas do conjunto de dados

Variável	Mín.	1º Qu.	Mediana	Média	3º Qu.	Máx.
fixed_acidity	3,800	6,400	7,000	7,215	7,700	15,900
volatile_acidity	0,0800	0,2300	0,2900	0,3397	0,4000	1,5800
citric_acid	0,0000	0,2500	0,3100	0,3186	0,3900	1,6600
residual_sugar	0,600	1,800	3,000	5,443	8,100	65,800
chlorides	0,00900	0,03800	0,04700	0,05603	0,06500	0,61100
free_sulfur_dioxide	1,00	17,00	29,00	30,53	41,00	289,00
total_sulfur_dioxide	6,0	77,0	118,0	115,7	156,0	440,0
density	0,9871	0,9923	0,9949	0,9947	0,9970	1,0390
p_h	2,720	3,110	3,210	3,219	3,320	4,010
sulphates	0,2200	0,4300	0,5100	0,5313	0,6000	2,0000
alcohol	8,00	9,50	10,30	10,49	11,30	14,90
quality	3,000	5,000	6,000	5,818	6,000	9,000

Tabela 5: Estatísticas descritivas completas das variáveis numéricas

Variável	n	Média	DP	Mediana	Média Ap.	MAD	Mín.	Máx.	Amplitude	Assimetria	Curtose	EP
fixed_acidity	6497	7,22	1,30	7,00	7,06	0,89	3,80	15,90	12,10	1,72	5,05	0,02
volatile_acidity	6497	0,34	0,16	0,29	0,32	0,12	0,08	1,58	1,50	1,49	2,82	0,00
citric_acid	6497	0,32	0,15	0,31	0,32	0,10	0,00	1,66	1,66	0,47	2,39	0,00
residual_sugar	6497	5,44	4,76	3,00	4,70	2,52	0,60	65,80	65,20	1,43	4,35	0,06
chlorides	6497	0,06	0,04	0,05	0,05	0,02	0,01	0,61	0,60	5,40	50,84	0,00
free_sulfur_dioxide	6497	30,53	17,75	29,00	29,32	17,79	1,00	289,00	288,00	1,22	7,90	0,22
total_sulfur_dioxide	6497	115,74	56,52	118,00	115,92	57,82	6,00	440,00	434,00	0,00	$-0,37$	0,70
density	6497	0,99	0,00	0,99	0,99	0,00	0,99	1,04	0,05	0,50	6,60	0,00
p_h	6497	3,22	0,16	3,21	3,21	0,16	2,72	4,01	1,29	0,39	0,37	0,00
sulphates	6497	0,53	0,15	0,51	0,52	0,12	0,22	2,00	1,78	1,80	8,64	0,00
alcohol	6497	10,49	1,19	10,30	10,40	1,33	8,00	14,90	6,90	0,57	$-0,53$	0,01
quality	6497	5,82	0,87	6,00	5,79	1,48	3,00	9,00	6,00	0,19	0,23	0,01

O conjunto de dados utilizado contém informações de 6497 vinhos, sendo 1599 vinhos tintos e 4898 vinhos brancos, conforme apresentado na Tabela 3. As estatísticas descritivas das variáveis quantitativas encontram-se nas Tabelas 4 e 5.

Observa-se que a variável resposta *quality* apresenta média igual a 5,82 pontos, mediana igual a 6 e desvio-padrão de 0,87 pontos, indicando baixa dispersão relativa quando

comparada à amplitude total da escala de qualidade, que varia de 3 a 9 pontos. As demais variáveis físico-químicas apresentam amplitudes distintas, refletindo a heterogeneidade natural dos processos de produção e fermentação dos vinhos.

A análise exploratória gráfica foi utilizada para complementar a descrição numérica dos dados, permitindo avaliar distribuições, dispersões, diferenças entre grupos e possíveis padrões relevantes para a etapa posterior de modelagem.

3.1.1 Distribuição da variável resposta

A Figura 1 apresenta a distribuição de frequências da variável resposta *qualidade dos vinhos*.

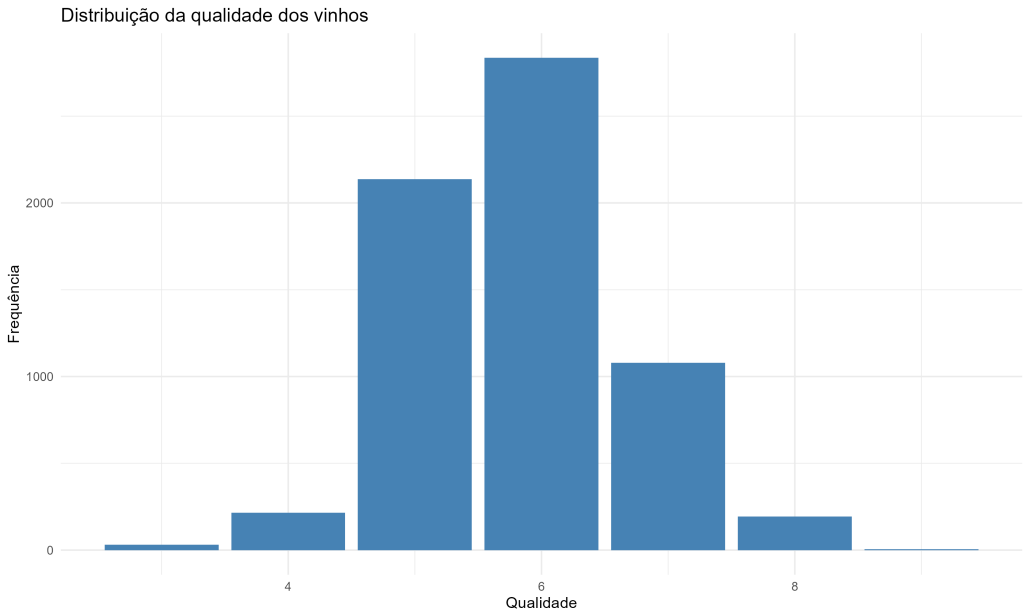


Figura 1: Distribuição da qualidade dos vinhos presentes no conjunto de dados.

A distribuição observada apresenta forte concentração das observações nas categorias de qualidade 5 e 6, que representam a maior parte da amostra analisada. As categorias extremas, correspondentes às qualidades 3, 4, 8 e 9, apresentam frequências substancialmente menores.

Esse comportamento é consistente com a média observada de 5,82 pontos e mediana igual a 6, apresentadas na Tabela 5. A proximidade entre média e mediana sugere uma distribuição aproximadamente centrada na região intermediária da escala de qualidade.

Do ponto de vista estatístico, essa concentração das observações em torno dos valores centrais indica que a maior parte da variabilidade da resposta ocorre em uma faixa relativamente estreita de qualidade, característica frequentemente observada em bancos de dados de avaliação sensorial de alimentos e bebidas. A existência de observações nas categorias extremas demonstra, entretanto, que há variabilidade suficiente para investigar o efeito dos fatores físico-químicos sobre a qualidade percebida dos vinhos.

3.1.2 Qualidade segundo o tipo de vinho

A comparação entre os tipos de vinho é apresentada na Figura 2.

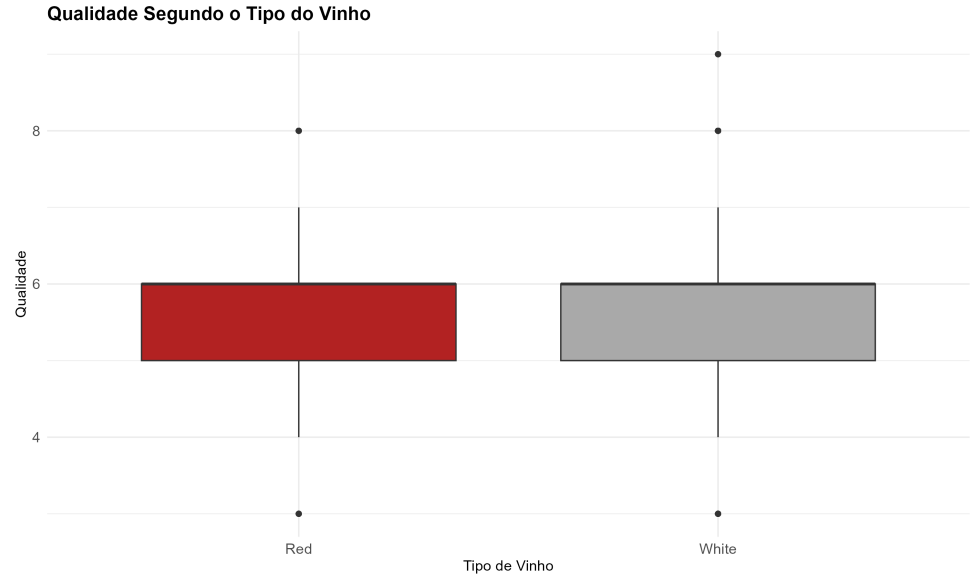


Figura 2: Distribuição da qualidade segundo o tipo de vinho.

Os boxplot permitem comparar simultaneamente medidas de posição, dispersão e possíveis observações extremas entre os grupos analisados.

Observa-se que ambos os tipos de vinho apresentam mediana igual a 6 pontos e intervalo interquartil semelhante, indicando que a variabilidade central da qualidade é comparável entre os grupos. Entretanto, os vinhos brancos apresentam maior presença de observações classificadas nas categorias superiores de qualidade, alcançando valores de até 9 pontos, enquanto os vinhos tintos apresentam menor frequência nessas categorias.

Essas diferenças visuais sugerem a existência de distinções sistemáticas entre os grupos, hipótese posteriormente investigada formalmente por meio do teste t de Welch e da análise de variância apresentados na Seção 3.4.

Sob a perspectiva experimental, essa comparação inicial justifica a inclusão da variável categórica *wine_type* como um dos fatores do planejamento fatorial fracionário, permitindo avaliar quantitativamente sua contribuição para a variabilidade observada na qualidade dos vinhos.

3.1.3 Distribuição do teor alcoólico por tipo de vinho

A Figura 3 apresenta a distribuição da variável álcool separadamente para vinhos tintos e brancos.

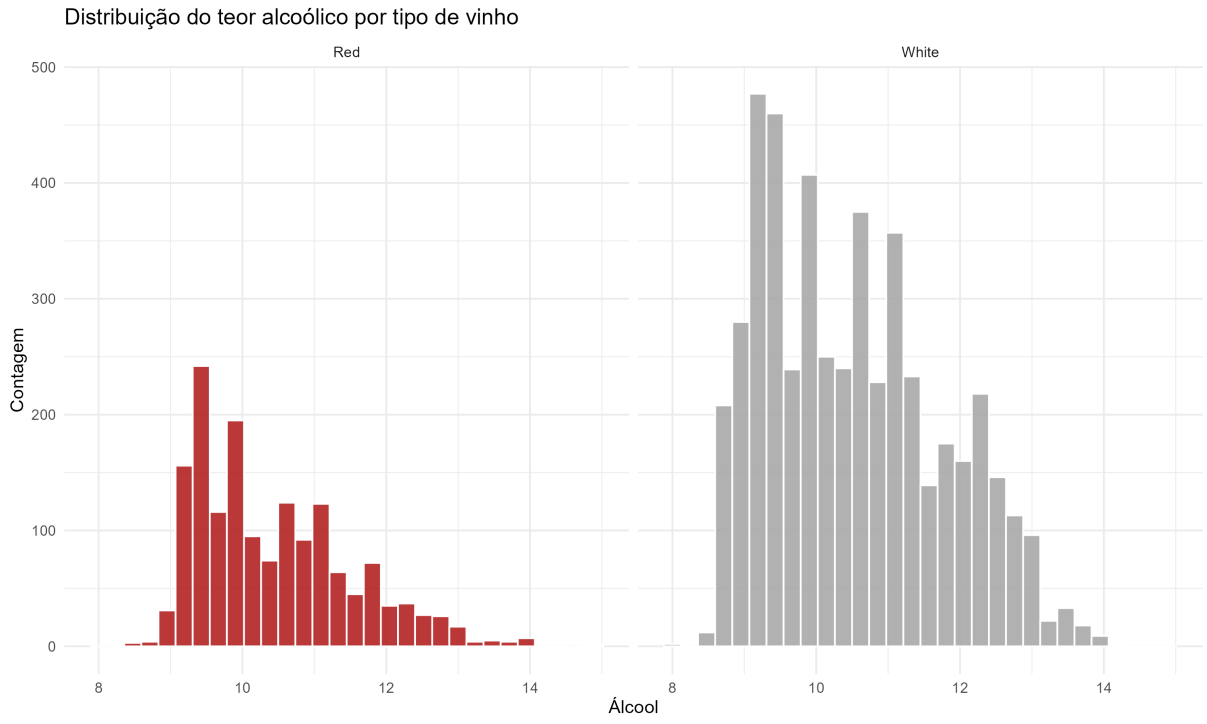


Figura 3: Distribuição do teor alcoólico segundo o tipo de vinho.

A variável teor alcoólico apresenta comportamento distinto entre os dois tipos de vinho. Os vinhos tintos concentram-se principalmente entre aproximadamente 9% e 11% de álcool, enquanto os vinhos brancos exibem distribuição mais dispersa, abrangendo uma faixa mais ampla de valores.

Além disso, observa-se maior frequência de vinhos brancos com teor alcoólico superior a 11%, sugerindo diferenças estruturais nos processos de fermentação e produção entre os grupos.

A relevância dessa variável para o estudo é reforçada pela literatura especializada, que frequentemente associa maiores concentrações de álcool a melhores avaliações sensoriais devido ao aumento da percepção de corpo, textura e complexidade aromática da bebida.

Dessa forma, a variável álcool foi selecionada como um dos fatores principais do planejamento experimental, sendo posteriormente representada pelo fator codificado A no delineamento fatorial fracionário.

3.1.4 Comparação das variáveis físico-químicas entre os tipos de vinho

A Figura 4 apresenta os boxplots das principais variáveis físico-químicas utilizadas no estudo, separados por tipo de vinho.

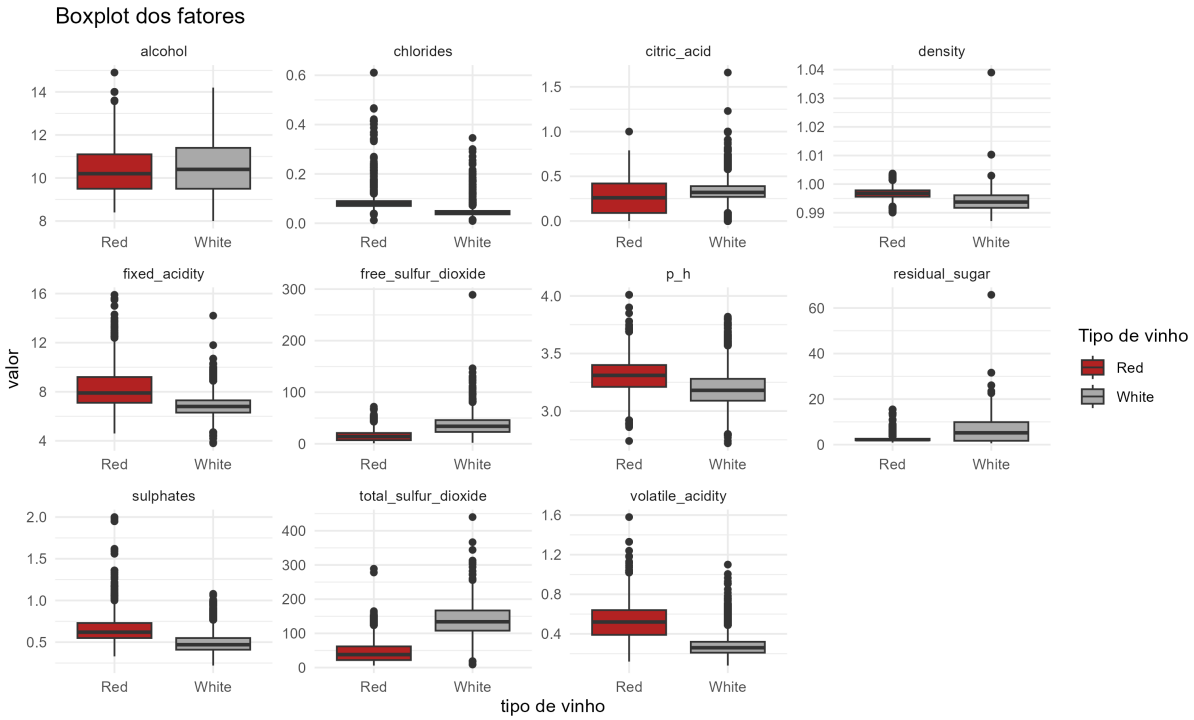


Figura 4: Distribuição das variáveis físico-químicas segundo o tipo de vinho.

Os resultados evidenciam diferenças substanciais entre vinhos tintos e brancos para diversas características químicas.

Os vinhos tintos apresentam, em geral, maiores valores de acidez fixa (*fixed acidity*), acidez volátil (*volatile acidity*), sulfatos (*sulphates*), cloretos (*chlorides*) e pH. Por outro lado, os vinhos brancos exibem maiores concentrações de açúcar residual (*residual sugar*), ácido cítrico (*citric acid*), dióxido de enxofre livre (*free sulfur dioxide*) e dióxido de enxofre total (*total sulfur dioxide*).

Diferenças também são observadas na densidade (*density*) e no teor alcoólico (*alcohol*), embora com menor magnitude relativa. A presença de numerosos valores extremos em algumas variáveis, particularmente açúcar residual, dióxido de enxofre e cloretos, evidencia a elevada heterogeneidade do conjunto de dados.

Sob a perspectiva estatística, essas diferenças justificam novamente a inclusão do tipo de vinho como fator experimental e sugerem a possibilidade de interações entre características físico-químicas e a classificação do vinho. Essas hipóteses serão investigadas posteriormente por meio da modelagem baseada em planejamento fatorial fracionário 2^k.

Além disso, os padrões observados indicam que parte da variabilidade da qualidade pode estar associada às diferenças estruturais entre os dois grupos, reforçando a importância de considerar simultaneamente variáveis químicas e categóricas na construção do modelo explicativo.

3.2 Análise das Relações entre Variáveis

Após a análise realizada na seção anterior , foi conduzida uma investigação das relações existentes entre os atributos físico-químicos e a variável resposta *quality*. Para isso, foram utilizadas uma matriz de correlação, gráficos de dispersão com linhas de tendência e uma matriz de dispersão das principais variáveis do estudo.

3.2.1 Matriz de Correlação

A Tabela 6 apresenta os coeficientes de correlação de Pearson entre todas as variáveis numéricas do conjunto de dados.

Tabela 6: Matriz de correlação entre as variáveis numéricas

Variável	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)	(10)	(11)	(12)
(1) fixed_acidity	1,00	0,22	0,32	−0,11	0,30	−0,28	−0,33	0,46	−0,25	0,30	−0,10	−0,08
(2) volatile_acidity	0,22	1,00	−0,38	−0,20	0,38	−0,35	−0,41	0,27	0,26	0,23	−0,04	−0,27
(3) citric_acid	0,32	−0,38	1,00	0,14	0,04	0,13	0,19	0,10	−0,33	0,06	−0,01	0,09
(4) residual_sugar	−0,11	−0,20	0,14	1,00	−0,13	0,40	0,50	0,55	−0,27	−0,19	−0,36	−0,04
(5) chlorides	0,30	0,38	0,04	−0,13	1,00	−0,20	−0,28	0,36	0,04	0,40	−0,26	−0,20
(6) free_sulfur_dioxide	−0,28	−0,35	0,13	0,40	−0,20	1,00	0,72	0,03	−0,15	−0,19	−0,18	0,06
(7) total_sulfur_dioxide	−0,33	−0,41	0,20	0,50	−0,28	0,72	1,00	0,03	−0,24	−0,28	−0,27	−0,04
(8) density	0,46	0,27	0,10	0,55	0,36	0,03	0,03	1,00	0,01	0,26	−0,69	−0,31
(9) p_h	−0,25	0,26	−0,33	−0,27	0,04	−0,15	−0,24	0,01	1,00	0,19	0,12	0,02
(10) sulphates	0,30	0,23	0,06	−0,19	0,40	−0,19	−0,28	0,26	0,19	1,00	−0,00	0,04
(11) alcohol	−0,10	−0,04	−0,01	−0,36	−0,26	−0,18	−0,27	−0,69	0,12	−0,00	1,00	0,44
(12) quality	−0,08	−0,27	0,09	−0,04	−0,20	0,06	−0,04	−0,31	0,02	0,04	0,44	1,00

Os resultados mostram que a variável álcool(*alcohol*) possui a maior correlação positiva com a qualidade ($r = 0,44$), indicando que vinhos com maior teor alcoólico tendem a receber avaliações superiores.

Por outro lado, a variável acidez volátil (*volatile_acidity*) apresenta correlação negativa moderada com a qualidade ($r = -0,27$), sugerindo que níveis elevados desse fator estão associados a vinhos de menor qualidade. De forma semelhante, a variável densidade (*density*) apresenta correlação negativa ainda mais pronunciada ($r = -0,31$), indicando que vinhos mais densos tendem a receber avaliações inferiores.

As demais variáveis apresentam correlações relativamente fracas com a qualidade, destacando-se:

- Ácido cítrico (*citric_acid*): $r = 0,09$;
- Dióxido sulfúrico livre (*free_sulfur_dioxide*): $r = 0,06$;
- Sulfatos (*sulphates*): $r = 0,04$;
- pH (p_h): $r = 0,02$;
- Açúcar residual (*residual_sugar*): $r = -0,04$.

Embora essas associações individuais sejam pequenas, elas podem contribuir conjuntamente para explicar a qualidade dos vinhos em modelos multivariados.

Além das relações com a variável resposta, algumas associações entre variáveis explicativas merecem destaque. A maior correlação observada foi entre Dióxido Sulfúrico Livre

(*free_sulfur_dioxide*) e Dióxido Sulfúrico Total (*total_sulfur_dioxide*) com $r = 0,72$, indicando forte dependência linear entre ambas.

Outra relação importante ocorre entre densidade (*density*) e álcool (*alcohol*), cuja correlação é fortemente negativa ($r = -0,69$), sugerindo que vinhos com maior teor alcoólico tendem a apresentar menor densidade. Também foi observada correlação positiva moderada entre densidade e açúcar residual ($r = 0,55$), evidenciando que maiores concentrações de açúcar residual aumentam a densidade da bebida.

Esses resultados sugerem a existência de colinearidade entre algumas variáveis explicativas, aspecto que deverá ser considerado em etapas posteriores de modelagem.

3.2.2 Mapa de Calor das Correlações

A Figura 5 apresenta a matriz de correlação em formato gráfico.

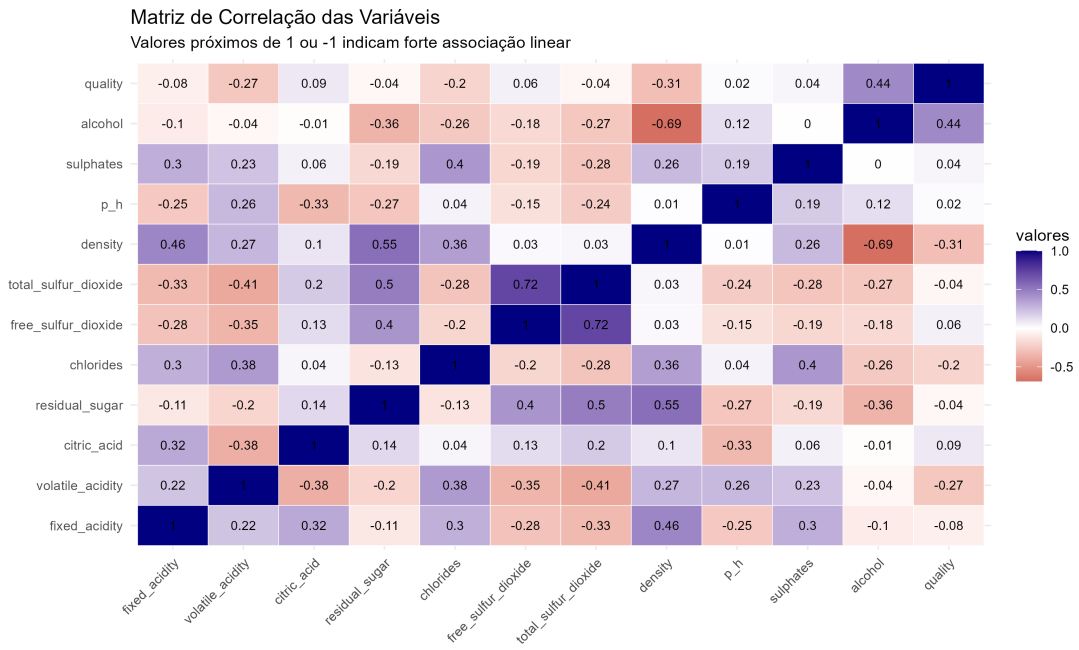


Figura 5: Mapa de calor da matriz de correlação das variáveis.

O mapa de calor permite visualizar rapidamente as associações positivas e negativas presentes nos dados. As regiões em tons mais escuros indicam correlações de maior magnitude.

Visualmente, destacam-se três padrões principais:

1. forte correlação positiva entre dióxido sulfúrico livre (*free_sulfur_dioxide*) e dióxido sulfúrico total (*total_sulfur_dioxide*);
2. forte correlação negativa entre densidade (*density*) e álcool (*alcohol*);
3. associação positiva entre álcool(*alcohol*) e qualidade (*quality*), acompanhada de associações negativas entre qualidade (*quality*), densidade (*density*) e acidez volátil (*volatile_acidity*).

Esses padrões confirmam os resultados obtidos na matriz numérica de correlação.

3.2.3 Qualidade versus Teor Alcoólico

A Figura 6 apresenta a relação entre o teor alcoólico e a qualidade dos vinhos, diferenciando vinhos tintos e brancos.

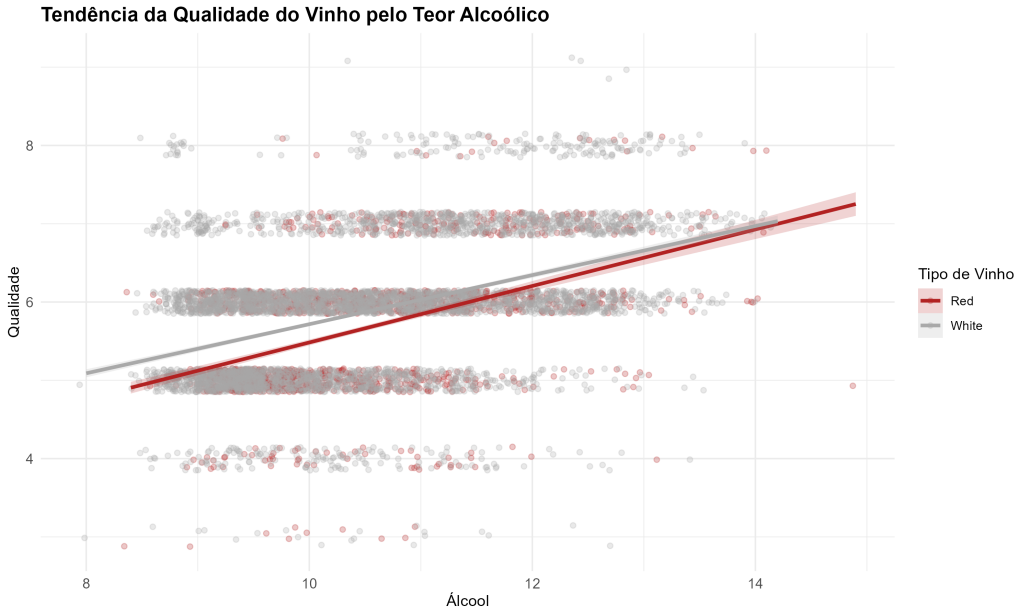


Figura 6: Relação entre teor alcoólico e qualidade do vinho.

Observa-se uma tendência crescente para ambos os tipos de vinho, indicando que maiores teores alcoólicos estão associados a maiores níveis de qualidade.

A inclinação positiva das retas de regressão confirma o resultado observado na matriz de correlação. Além disso, nota-se que o efeito é ligeiramente mais pronunciado para os vinhos tintos, cuja inclinação apresenta maior intensidade.

Apesar da tendência positiva, existe dispersão considerável dos dados, indicando que o teor alcoólico não é o único fator responsável pela qualidade do vinho.

3.2.4 Qualidade versus Acidez Volátil

A Figura 7 mostra a relação entre qualidade e acidez volátil.

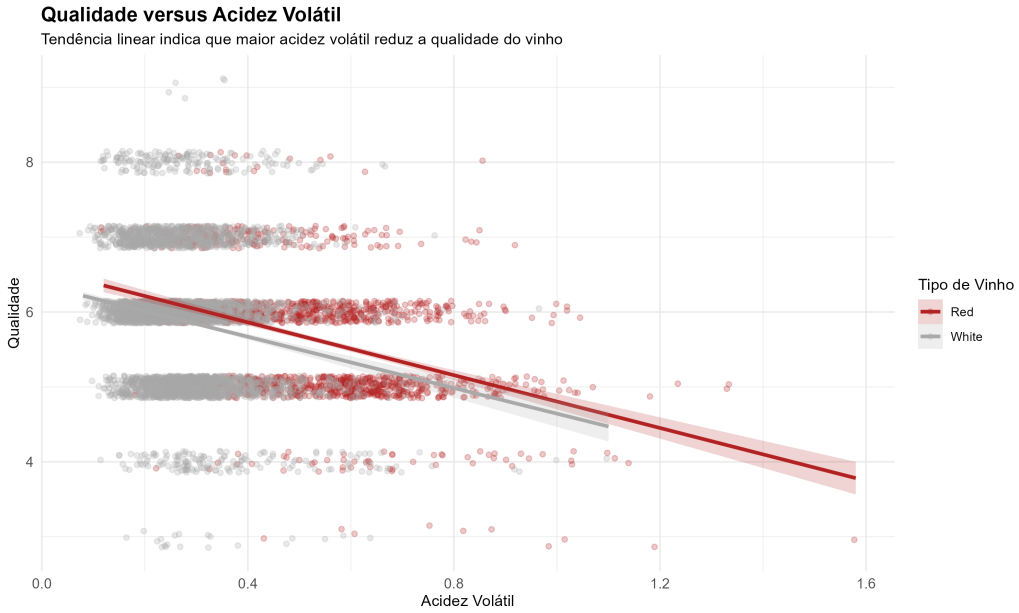


Figura 7: Relação entre acidez volátil e qualidade do vinho.

A tendência observada é claramente negativa, indicando que aumentos na acidez volátil estão associados à redução da qualidade dos vinhos.

Esse resultado está de acordo com o conhecimento enológico, uma vez que concentrações elevadas de compostos responsáveis pela acidez volátil costumam gerar aromas e sabores indesejáveis.

A inclinação negativa é mais acentuada entre os vinhos tintos, sugerindo que esse atributo exerce influência mais forte sobre a qualidade desse grupo.

3.2.5 Matriz de Dispersão

Para complementar a análise bivariada, foi construída uma matriz de dispersão (Figura 8) contendo as variáveis mais relevantes para a qualidade do vinho: qualidade (*quality*), álcool (*alcohol*), acidez volátil (*volatile_ acidity*), sulfatos (*sulphates*) e densidade (*density*).

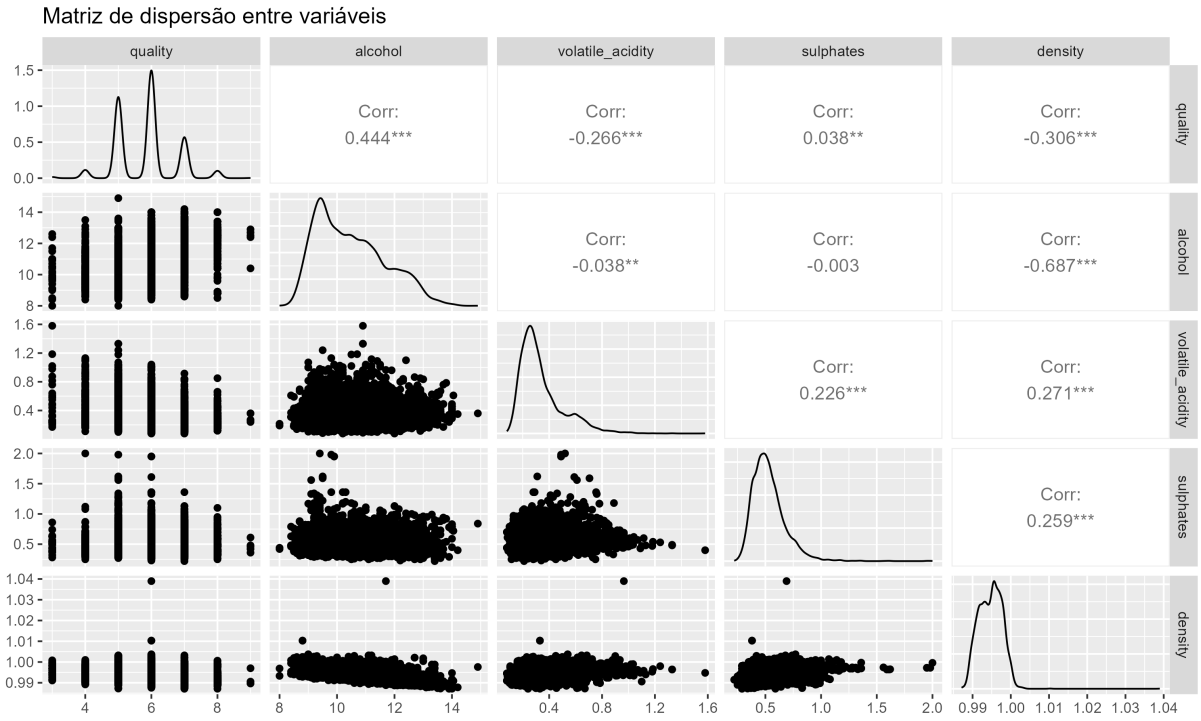


Figura 8: Matriz de dispersão entre as principais variáveis do estudo.

Na diagonal principal são apresentadas as distribuições individuais de cada variável. Observa-se que a qualidade possui distribuição concentrada entre os níveis 5 e 7, enquanto o teor alcoólico apresenta distribuição assimétrica à direita.

Fora da diagonal principal, os gráficos de dispersão permitem identificar padrões consistentes com os resultados observados anteriormente.

A associação positiva mais evidente ocorre entre qualidade e álcool ($r = 0,444$), indicando que vinhos com maior teor alcoólico tendem a obter melhores avaliações.

Por outro lado, observam-se associações negativas entre qualidade e acidez volátil ($r = -0,266$) e entre qualidade e densidade ($r = -0,306$), sugerindo que maiores valores dessas variáveis estão associados à redução da qualidade.

Outro padrão importante é a forte relação negativa entre densidade e álcool ($r = -0,687$), confirmando uma das maiores correlações observadas na base de dados.

Em geral, os gráficos não indicam a presença de relações fortemente não lineares, sugerindo que modelos lineares podem representar adequadamente grande parte das associações observadas.

3.2.6 Síntese da Análise Relacional

A análise conjunta dos gráficos e da matriz de correlação indica que o teor alcoólico é o atributo individual mais associado à qualidade dos vinhos, apresentando correlação positiva moderada. Em contraste, a acidez volátil e a densidade apresentam correlações negativas, indicando que níveis elevados desses atributos tendem a reduzir a avaliação final do produto.

Além disso, foram identificadas correlações elevadas entre algumas variáveis explicativas, especialmente entre dióxido sulfúrico livre e dióxido sulfúrico total, bem como entre densidade e álcool. Esses resultados fornecem evidências importantes para a seleção de variáveis e para a construção de modelos estatísticos nas etapas subsequentes do estudo.

3.3 Planejamento Fatorial Fracionário

Com o objetivo de investigar simultaneamente os efeitos dos fatores físico-químicos associados à qualidade dos vinhos, foi adotado um planejamento fatorial fracionário de dois níveis, construído a partir da função `FrF2` do software `R`.

Considerando sete fatores experimentais, um planejamento fatorial completo exigiria a realização de $2^7 = 128$ corridas experimentais. Entretanto, a execução de todas as combinações possíveis implicaria elevado custo computacional e maior complexidade de análise.

Dessa forma, optou-se pela utilização de um planejamento fracionário 2^{7-3}, correspondente a uma fração de um oitavo do experimento completo. Essa estratégia reduziu o número de corridas para apenas 16 experimentos, preservando a capacidade de estimar os principais efeitos dos fatores e reduzindo significativamente o esforço experimental.

3.3.1 Matriz do Delineamento Experimental

A Tabela 7 apresenta a matriz do delineamento experimental adotado.
Os fatores considerados foram:

- A: teor alcoólico (*alcohol*);
- B: acidez volátil (*volatile acidity*);
- C: sulfatos (*sulphates*);
- D: densidade (*density*);
- E: tipo de vinho (*wine type*);
- F: açúcar residual (*residual sugar*);
- G: ácido cítrico (*citric acid*).

Tabela 7: Matriz do delineamento experimental fatorial fracionário 2^{7-3}

Ensaio	A	B	C	D	E = ABC	F = BCD	G = ACD
1	−1	−1	−1	−1	−1	−1	−1
2	1	−1	−1	−1	1	1	1
3	−1	1	−1	−1	1	1	−1
4	1	1	−1	−1	−1	−1	1
5	−1	−1	1	−1	1	−1	1
6	1	−1	1	−1	−1	1	−1
7	−1	1	1	−1	−1	1	1
8	1	1	1	−1	1	−1	−1
9	−1	−1	−1	1	−1	1	1
10	1	−1	−1	1	1	−1	−1
11	−1	1	−1	1	1	−1	1
12	1	1	−1	1	−1	1	−1
13	−1	−1	1	1	1	1	−1
14	1	−1	1	1	−1	−1	1
15	−1	1	1	1	−1	−1	−1
16	1	1	1	1	1	1	1

Os fatores A, B, C e D foram definidos como fatores básicos do planejamento, enquanto os fatores E, F e G foram gerados a partir das seguintes relações:

$$E = ABC,$$
$$F = BCD,$$
$$G = ACD.$$

Esses geradores definem a estrutura da fração utilizada e garantem a ortogonalidade do delineamento, permitindo a estimação eficiente dos efeitos principais.

3.3.2 Características do Planejamento

As principais características do delineamento são apresentadas na Tabela 8.

Tabela 8: Características gerais do planejamento experimental

Propriedade	Especificação
Tipo de Planejamento	Fatorial Fracionário (FrF2)
Delineamento Base	$7 - 3.1$
Resolução	IV
Número de Fatores	7
Corridas Utilizadas	16
Corridas no Planejamento Completo	128
Economia Experimental	87,5%

Observa-se que o planejamento possui resolução IV. Em delineamentos dessa resolução, os efeitos principais não ficam confundidos entre si nem com interações de dois fatores. Entretanto, algumas interações de segunda ordem podem estar confundidas entre si.

Uma das principais vantagens desse delineamento é a economia experimental obtida. Enquanto o experimento completo exigiria 128 corridas, a fração selecionada utiliza apenas 16 corridas, representando uma redução de aproximadamente 87,5% no número de experimentos necessários.

Essa redução torna o planejamento particularmente atrativo em situações nas quais a coleta de dados é custosa ou quando se deseja realizar uma etapa inicial de triagem dos fatores mais importantes.

3.3.3 Estrutura de Confundimento

A estrutura de confundimento das interações de dois fatores é apresentada na Tabela 9.

Tabela 9: Estrutura de confundimento para interações de dois fatores

Grupo	Interações Aliadas (Confundidas)
1	$AB = CE = DF$
2	$AC = BE = DG$
3	$AD = BF = CG$
4	$AE = BC = FG$
5	$AF = BD = EG$
6	$AG = CD = EF$
7	$BG = CF = DE$

A análise dessa estrutura permite identificar quais efeitos não podem ser estimados separadamente utilizando apenas os dados provenientes desse delineamento.

Por exemplo, o grupo

$$AB = CE = DF$$

indica que o efeito estimado experimentalmente corresponde à combinação das interações AB, CE e DF. Consequentemente, não é possível determinar qual dessas interações é responsável individualmente pelo efeito observado.

De forma semelhante, as demais relações de alias apresentadas na Tabela 9 mostram quais pares de fatores compartilham a mesma informação experimental.

Apesar dessa limitação, delineamentos de resolução IV são amplamente utilizados em estudos exploratórios e de triagem, pois permitem identificar os fatores mais influentes utilizando uma quantidade substancialmente menor de experimentos.

3.3.4 Considerações Finais

O planejamento fatorial fracionário 2^{7-3} mostrou-se adequado para a investigação simultânea dos sete fatores considerados neste estudo. A elevada economia experimental obtida, associada à preservação da estimabilidade dos efeitos principais, torna esse delineamento uma alternativa eficiente ao planejamento completo.

Além disso, a estrutura de resolução IV garante que os efeitos principais possam ser interpretados sem confundimento com interações de segunda ordem, possibilitando a identificação dos fatores potencialmente mais relevantes para a qualidade dos vinhos.

3.4 Análise dos Efeitos

A Figura 9 apresenta o diagrama de Pareto dos efeitos estimados.

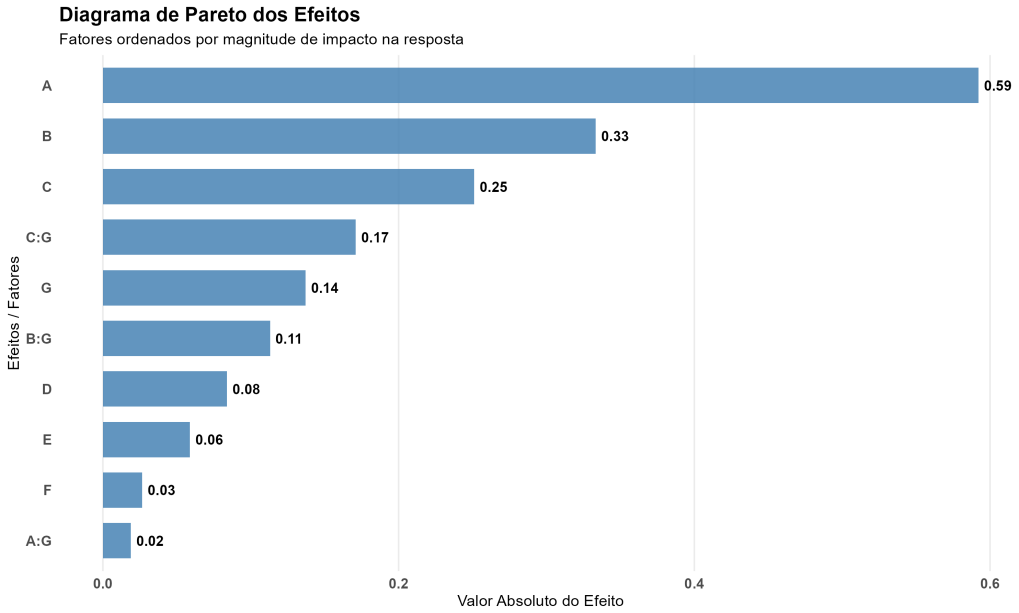


Figura 9: Diagrama de Pareto dos efeitos estimados.

Observa-se que o fator A (teor alcoólico) apresenta o maior efeito absoluto sobre a qualidade dos vinhos, com magnitude aproximada de 0,59. Em seguida aparecem os fatores B (acidez volátil) e C (densidade), com efeitos de aproximadamente 0,33 e 0,25, respectivamente.

Esses resultados corroboram as conclusões obtidas na análise exploratória da Seção 3.2, na qual o teor alcoólico apresentou a maior correlação positiva com a qualidade ($r = 0,44$), enquanto a acidez volátil e a densidade apresentaram correlações negativas moderadas.

Também se destacam algumas interações, principalmente C:G e B:G, indicando que o impacto de determinadas variáveis pode depender do nível de outras características químicas do vinho.

3.4.1 Modelo de Regressão dos Efeitos

Para quantificar os efeitos observados foi ajustado um modelo de regressão linear considerando os fatores principais e as interações mais relevantes. Os resultados encontram-se na Tabela 10.

Tabela 10: Coeficientes e estatísticas de ajuste do modelo de regressão linear

Termo	Estimativa (β)	Erro Padrão	Valor t	Pr($>\|t\|$)
(Intercepto)	5,7816	0,0228	253,439	$< 2 \times 10^{-16}$ ***
A	0,2961	0,0129	23,028	$< 2 \times 10^{-16}$ ***
B	$-0,1667$	0,0196	$-8,517$	$< 2 \times 10^{-16}$ ***
C	0,1255	0,0161	7,795	$7,44 \times 10^{-15}$ ***
D	$-0,0420$	0,0132	$-3,192$	0,0014 **
E	0,0294	0,0105	2,812	0,0049 **
F	0,0133	0,0102	1,305	0,1919
G	0,0685	0,0235	2,914	0,0036 **
A:G	0,0094	0,0117	0,802	0,4227
B:G	0,0565	0,0194	2,911	0,0036 **
C:G	$-0,0855$	0,0160	$-5,331$	$1,01 \times 10^{-7}$ ***
Erro padrão residual: 0,7878 com 6486 graus de liberdade				
R^2 Múltiplo: 0,1875; R^2 Ajustado: 0,1862				
Estatística F: 149,7 com 10 e 6486 GL (p-valor $< 2,2 \times 10^{-16}$)				
Códigos de significância: 0 '***' 0,001 '**' 0,01 '*' 0,05 '.' 0,1 ' ' 1				

O modelo foi globalmente significativo ($F = 149,7$, $p < 2,2 \times 10^{-16}$), indicando que o conjunto de variáveis explica uma parcela significativa da variabilidade observada na qualidade dos vinhos.

Os coeficientes estimados revelam que:

- O teor alcoólico (A) exerce efeito positivo significativo sobre a qualidade ($\beta = 0,2961$);
- A acidez volátil (B) apresenta efeito negativo significativo ($\beta = -0,1667$), indicando redução da qualidade à medida que sua concentração aumenta;
- A densidade (C) apresenta efeito positivo no modelo codificado, sendo estatisticamente significativa;
- Sulfatos (D), tipo de vinho (E) e ácido cítrico (G) também apresentam efeitos significativos, embora de menor magnitude;
- O fator F (açúcar residual) não apresentou significância estatística ao nível de 5%;
- Entre as interações avaliadas, destacam-se B:G e C:G como estatisticamente significativas.

Apesar da significância global do modelo, o coeficiente de determinação foi relativamente baixo ($R^2 = 0,1875$), indicando que aproximadamente 18,75% da variabilidade da qualidade é explicada pelos fatores considerados. Esse resultado era esperado, pois a qualidade do vinho é influenciada por diversos aspectos sensoriais e químicos não incluídos no modelo.

3.4.2 Análise de Variância dos Efeitos

A Tabela 11 apresenta os resultados da análise de variância associada ao modelo ajustado.

Tabela 11: Tabela da Análise de Variância (ANOVA) para o modelo de qualidade

Termo	GL	Sum Sq	Mean Sq	F value	p-value
A	1	329,13	329,13	530,3442	$< 2,2 \times 10^{-16}$ ***
B	1	45,02	45,02	72,5447	$< 2,2 \times 10^{-16}$ ***
C	1	37,71	37,71	60,7578	$7,44 \times 10^{-15}$ ***
D	1	6,32	6,32	10,1873	0,0014 **
E	1	4,91	4,91	7,9079	0,0049 **
F	1	1,06	1,06	1,7032	0,1919
G	1	5,27	5,27	8,4901	0,0036 **
A:G	1	0,40	0,40	0,6433	0,4226
B:G	1	5,26	5,26	8,4751	0,0036 **
C:G	1	17,64	17,64	28,4239	$1,01 \times 10^{-7}$ ***
Resíduos	6486	4025,21	0,6206	—	—

Códigos de significância: 0 '***' 0,001 '**' 0,01 '*' 0,05 '.' 0,1 ' ' 1

Os maiores valores de soma de quadrados foram observados para os fatores A, B e C, confirmando sua predominância na explicação da variabilidade da resposta.

O teor alcoólico apresentou a maior contribuição individual ($SQ = 329,13$), seguido pela acidez volátil ($SQ = 45,02$) e pela densidade ($SQ = 37,71$).

Esses resultados reforçam as evidências obtidas tanto na matriz de correlação (Figura 5) quanto no diagrama de Pareto (Figura 9).

3.4.3 Influência do Tipo de Vinho

Foi realizado um teste t de Welch para comparar a qualidade média entre vinhos tintos e brancos.

A Tabela 12 apresenta os resultados obtidos.

Tabela 12: Resultados do Teste t de Welch (Qualidade por Tipo de Vinho)

Estatística	Resultado
Estatística t	-10,149
Graus de Liberdade (GL)	2950,8
p-valor	$< 2,2 \times 10^{-16}$
Média (Vinho Tinto)	5,6360
Média (Vinho Branco)	5,8779
Intervalo de Confiança (95%)	$[-0,2886; -0,1952]$

O teste indicou diferença estatisticamente significativa entre os grupos ($p < 2,2 \times 10^{-16}$).

A qualidade média observada para os vinhos brancos foi de 5,878, enquanto os vinhos tintos apresentaram média de 5,636.

O intervalo de confiança de 95% para a diferença entre as médias não contém o valor zero, reforçando a evidência de diferença entre os tipos de vinho.

Essa conclusão também foi confirmada pela análise de variância apresentada na Tabela 13.

Tabela 13: Análise de Variância (ANOVA) para Qualidade em função do Tipo de Vinho

Fonte de Variação	GL	Sum Sq	Mean Sq	F value	p-value
Tipo de Vinho (*wine_type*)	1	70,5	70,531	93,812	$< 2,2 \times 10^{-16}$ ***
Resíduos	6495	4883,2	0,752	—	—

Códigos de significância: 0 '***' 0,001 '**' 0,01 '*' 0,05 '.' 0,1 ' ' 1

O efeito do tipo de vinho foi altamente significativo ($F = 93,81$; $p < 2,2 \times 10^{-16}$), indicando que a classificação do vinho influencia a qualidade média observada.

3.4.4 Interação entre Tipo de Vinho e Teor Alcoólico

A Figura 10 apresenta o gráfico de interação entre o teor alcoólico e o tipo de vinho.

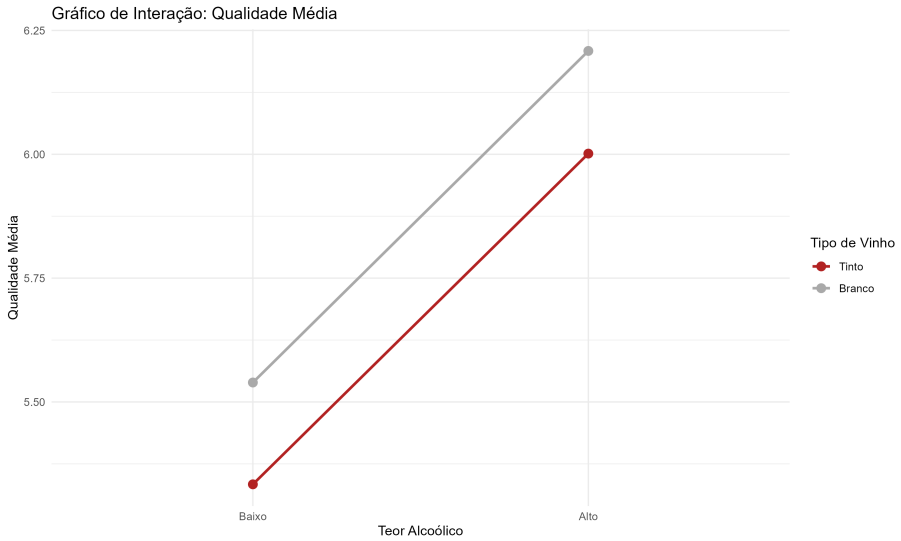


Figura 10: Interação entre teor alcoólico e tipo de vinho para a qualidade média.

Observa-se que o aumento do teor alcoólico está associado a um aumento da qualidade média para ambos os tipos de vinho.

Os vinhos brancos apresentam qualidade média superior aos vinhos tintos tanto no nível baixo quanto no nível alto de teor alcoólico.

Além disso, as retas apresentam inclinações semelhantes, sugerindo que a influência do teor alcoólico sobre a qualidade ocorre de maneira relativamente consistente entre os dois tipos de vinho, sem evidências de uma interação muito pronunciada.

3.4.5 Síntese dos Resultados

De maneira geral, os resultados do planejamento fatorial fracionário indicam que o teor alcoólico é o fator mais importante para explicar a qualidade dos vinhos avaliados.

Em contraste, a acidez volátil exerce efeito negativo significativo, reduzindo a qualidade à medida que aumenta.

A análise também evidenciou diferenças estatisticamente significativas entre vinhos tintos e brancos, sendo os vinhos brancos associados, em média, a maiores escores de qualidade.

As conclusões obtidas pelo planejamento experimental foram consistentes com os resultados observados anteriormente na análise exploratória dos dados, reforçando a robustez das interpretações realizadas ao longo do estudo.

3.5 Diagnóstico do Modelo

Após o ajuste do modelo linear correspondente ao planejamento fatorial fracionário 2^k, foram realizadas análises gráficas e testes formais para verificar a adequação dos pressupostos do modelo.

3.5.1 Análise gráfica dos resíduos

A Figura 11 apresenta os resíduos em função dos valores ajustados.

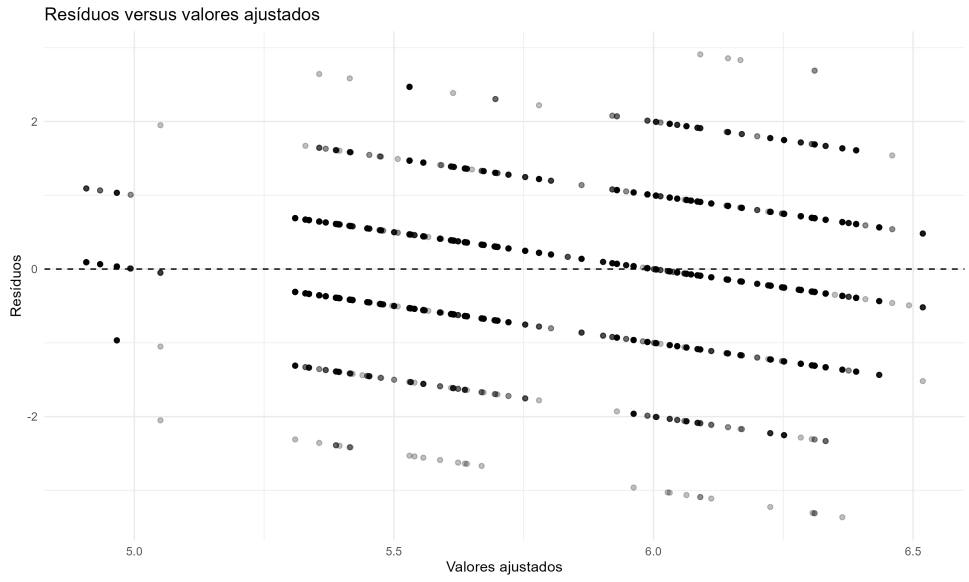


Figura 11: Resíduos versus valores ajustados.

Observa-se que os resíduos encontram-se distribuídos em faixas aproximadamente paralelas. Esse comportamento é esperado devido à natureza discreta da variável resposta, uma vez que a qualidade dos vinhos é medida por notas inteiras. Apesar desse padrão, não são observadas tendências sistemáticas acentuadas que indiquem falhas graves na especificação do modelo.

A distribuição dos resíduos é apresentada na Figura 12.

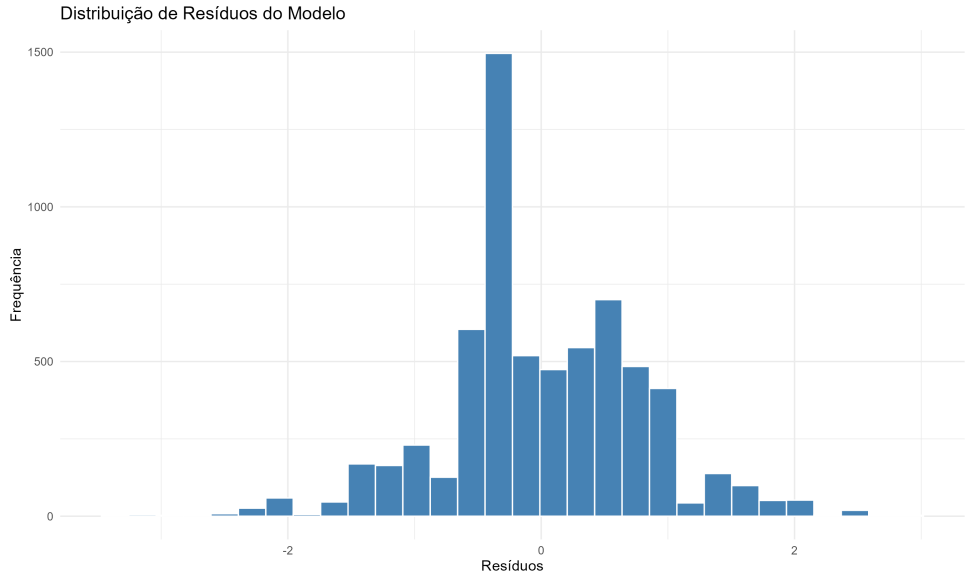


Figura 12: Histograma dos resíduos do modelo.

Verifica-se uma distribuição aproximadamente simétrica em torno de zero, embora com algumas concentrações associadas à natureza discreta da variável resposta.

A Figura 13 apresenta o gráfico de probabilidade normal dos resíduos.

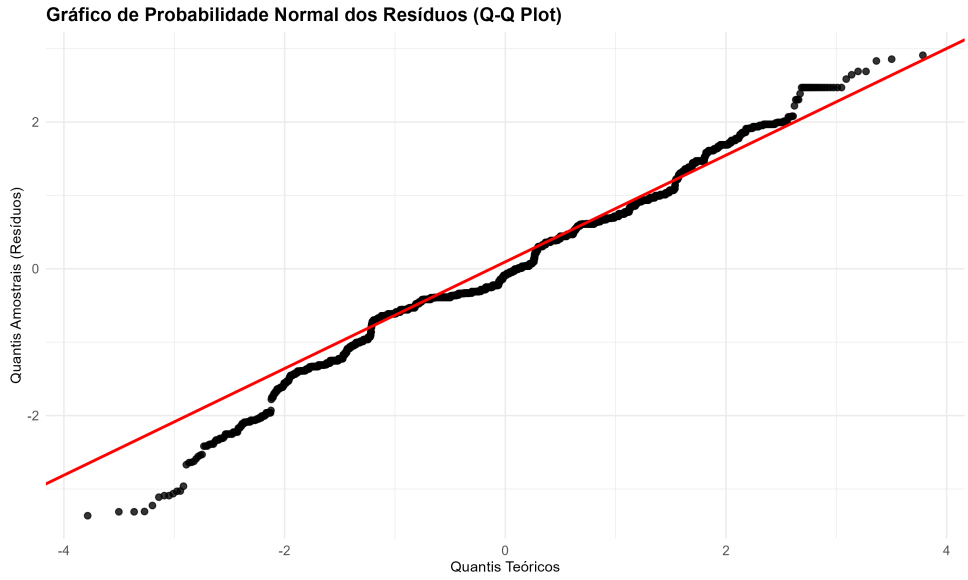


Figura 13: Gráfico Q-Q dos resíduos.

Observa-se boa aderência à reta de referência na região central da distribuição. Entretanto, desvios mais pronunciados são observados nas caudas, indicando pequenas violações da hipótese de normalidade.

3.5.2 Teste de normalidade

Para avaliar formalmente a normalidade dos resíduos foi aplicado o teste de Shapiro-Wilk, cujos resultados são apresentados na Tabela 14.

Tabela 14: Teste de Normalidade de Shapiro-Wilk para os Resíduos do Modelo

Métrica	Valor
Dados	`sample(residuals(mod), 500)`
Estatística W	0,98362
p-valor	$2,04 \times 10^{-5}$

Nota: Como o p-valor é menor que 0,05, rejeita-se a hipótese nula de normalidade dos resíduos.

O teste produziu estatística $W = 0,98362$ e p-valor igual a $2,04 \times 10^{-5}$. Dessa forma, rejeita-se a hipótese nula de normalidade ao nível de significância de 5%.

Entretanto, considerando o grande tamanho amostral ($n \approx 6500$), pequenas discrepâncias em relação à distribuição normal tendem a produzir rejeições do teste. Além disso, o gráfico Q-Q (Figura 13) mostrou que os desvios de normalidade concentram-se principalmente nas extremidades da distribuição, sugerindo que a aproximação normal permanece razoável para fins inferenciais.

3.5.3 Teste de homocedasticidade

A homogeneidade das variâncias foi avaliada por meio do teste de Breusch-Pagan, apresentado na Tabela 15.

Tabela 15: Teste de Breusch-Pagan (Estudentizado) para Homocedasticidade

Métrica	Valor
Dados	`mod`
Estatística BP	144,91
Graus de Liberdade (GL)	10
p-valor	$< 2,2 \times 10^{-16}$

Nota: Como o p-valor é significativamente menor que 0,05, rejeita-se a hipótese nula de homocedasticidade, indicando a presença de heterocedasticidade nos resíduos do modelo.

O teste resultou em estatística BP igual a 144,91 e p-valor inferior a $2,2 \times 10^{-16}$, levando à rejeição da hipótese nula de homocedasticidade.

Esse resultado indica a presença de heterocedasticidade nos resíduos, isto é, a variabilidade dos erros não permanece constante ao longo dos valores ajustados. Tal comportamento é relativamente comum em bases observacionais de grande porte e sugere cautela na interpretação estrita dos erros-padrão estimados pelo modelo.

3.5.4 Autocorrelação dos resíduos

A independência dos resíduos foi investigada por meio do teste de Durbin-Watson, cujos resultados encontram-se na Tabela 16.

Tabela 16: Teste de Durbin-Watson para Autocorrelação dos Resíduos

Métrica	Valor
Dados	`mod`
Estatística DW	1.7066
p-valor	$< 2,2 \times 10^{-16}$
Hipótese Alternativa	A verdadeira autocorrelação é maior que 0

Nota: Como o p-valor é menor que 0,05, rejeita-se a hipótese nula de ausência de autocorrelação. O resultado indica a presença de autocorrelação positiva nos resíduos do modelo.

A estatística obtida foi $DW = 1,7066$, com p-valor inferior a $2,2 \times 10^{-16}$, indicando evidências estatísticas de autocorrelação positiva.

Contudo, deve-se destacar que os dados analisados não constituem uma série temporal. Assim, embora o teste detecte dependência entre observações consecutivas na ordem em que os dados foram armazenados, esse resultado possui relevância prática limitada para os objetivos do presente estudo.

3.5.5 Análise de observações influentes

A influência individual das observações foi investigada por meio da Distância de Cook, apresentada na Figura 14.

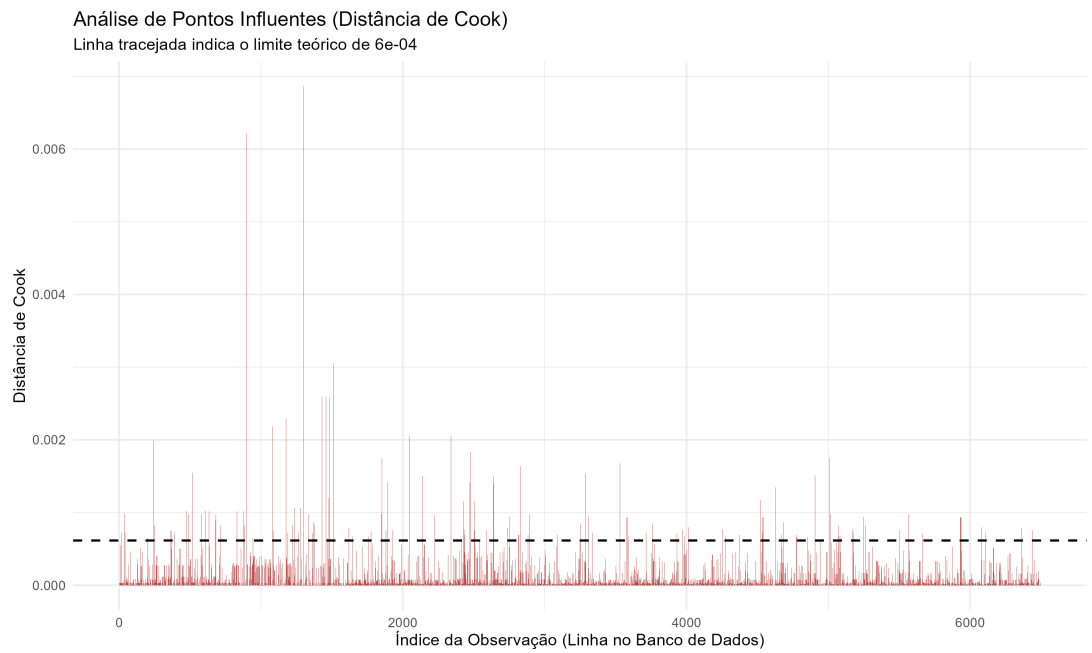


Figura 14: Distância de Cook para identificação de observações influentes.

Utilizando como referência o limite teórico $4/n \approx 6 \times 10^{-4}$, foram identificadas 319 observações potencialmente influentes.

Apesar disso, os valores observados permanecem relativamente baixos em termos absolutos, não havendo evidências de observações isoladas capazes de comprometer substancialmente o ajuste global do modelo. Dessa forma, optou-se por manter todas as observações na análise.

3.5.6 Conclusão do diagnóstico

Os diagnósticos realizados indicaram pequenas violações dos pressupostos clássicos do modelo linear. Foram observadas evidências de não normalidade dos resíduos, heterocedasticidade e autocorrelação estatisticamente significativa.

Entretanto, considerando o elevado tamanho amostral da base de dados e o caráter exploratório do planejamento fatorial empregado, tais violações não comprometem as principais conclusões do estudo. Os efeitos estimados permanecem consistentes e permitem identificar os fatores que exercem maior influência sobre a qualidade dos vinhos.

Assim, o modelo é considerado adequado para os objetivos de triagem e interpretação dos efeitos principais investigados neste trabalho.

4 Discussão Crítica

Vantagens:

O planejamento fatorial fracionário permitiu redução substancial do número de experimentos necessários, tornando a análise computacionalmente eficiente. Houve economia superior a 80% em relação ao planejamento completo.

Além disso, a metodologia possibilitou identificar fatores potencialmente relevantes sem necessidade de avaliar todas as combinações possíveis.

Em suma, as vantagens de se utilizar o experimento fatorial fracionário 2^k são:

- Redução significativa do número de experimentos necessários em comparação com um planejamento fatorial completo.
- Economia de tempo, recursos computacionais e custos experimentais, especialmente em problemas com grande quantidade de fatores.
- Possibilidade de identificar rapidamente os fatores mais influentes sobre a variável resposta.
- Aplicação eficiente em etapas iniciais de investigação, funcionando como uma ferramenta de triagem (*screening*) para estudos posteriores.

Limitações:

Planejamentos fracionários apresentam estruturas de confundimento entre efeitos. Dessa forma, determinados efeitos principais podem estar associados a interações, dificultando interpretações.

Outra limitação refere-se à transformação das variáveis contínuas em fatores binários, processo que reduz parte da informação disponível.

Assim, conclui-se que as limitações de um experimento fatorial fracionário são:

- Presença de confundimento (*aliasing*) entre efeitos principais e interações, dificultando a interpretação dos resultados.
- Possibilidade de perda de informação devido à utilização de apenas uma fração do experimento completo.
- Dependência da hipótese de que interações de ordem superior são desprezíveis, o que nem sempre é válido em sistemas complexos.
- Transformação de variáveis contínuas em fatores binários, podendo reduzir a riqueza das informações disponíveis.

Melhorias:
Como trabalhos futuros sugere-se:

- Utilização de planejamentos fatoriais fracionários de resolução superior para reduzir ambiguidades entre os efeitos.
- Realização de experimentos complementares para desfazer estruturas de confundimento identificadas na análise inicial.
- Inclusão de termos quadráticos e metodologias de superfície de resposta para capturar relações não lineares.
- Comparação dos resultados com modelos de aprendizado de máquina e técnicas modernas de seleção automática de variáveis.
- Uso de estratégias sequenciais, iniciando com um planejamento fracionário e expandindo-o conforme necessário.

5 Conclusão

A aplicação do Planejamento de Experimentos, especificamente por meio do delineamento fatorial fracionário 2^{7-3} com Resolução IV, mostrou-se uma estratégia altamente eficiente para a triagem (*screening*) das propriedades físico-químicas determinantes na qualidade do vinho utilizando o conjunto de dados *Wine Quality* [3] . A abordagem metodológica viabilizou uma economia experimental substancial de 87,5%, reduzindo o cenário analítico de 128 corridas para apenas 16 ensaios fundamentais, preservando a capacidade de estimar os efeitos principais sem confundimento com interações de segunda ordem.

Os resultados modelados revelaram de forma consistente que o teor alcoólico (Fator A) desponta como o elemento de maior impacto positivo na percepção de qualidade do produto, ao passo que a acidez volátil (Fator B) atua como o principal detrator sensorial. Adicionalmente, o estudo desvelou interações bi-fatoriais significativas envolvendo o ácido cítrico (Fator G) com a acidez volátil e a densidade, indicando que o comportamento dessas variáveis é interdependente no produto final. Paralelamente, os testes de hipóteses formais confirmaram uma sutil, porém estatisticamente significativa, superioridade na qualidade média atribuída aos vinhos brancos em relação aos vinhos tintos na base histórica.

Embora o diagnóstico dos resíduos tenha apontado violações dos pressupostos clássicos de linearidade (presença de heterocedasticidade e desvios de normalidade nas caudas), que é um fenômeno compreensível diante da escala discreta da variável resposta e do expressivo tamanho amostral ($n \approx 6500$), e o coeficiente de determinação tenha se mostrado modesto ($R^2 = 18,75\%$), o modelo cumpriu com rigor o seu propósito exploratório. Em suma, este trabalho valida a adaptação bem-sucedida de conceitos do delineamento industrial a bases de dados observacionais complexas, consolidando-se como uma ferramenta estatística robusta, de baixo custo computacional e de grande valia para o entendimento e a otimização de processos na indústria enológica.

Referências

[1] Montgomery, D. C. (2017). *Design and Analysis of Experiments*, 9th edition. John Wiley & Sons, New York. ISBN: 9781119113478.

[2] Cortez, P.; Cerdeira, A.; Almeida, F.; Matos, T.; Reis, J. (2009). *Modeling Wine Preferences by Data Mining from Physicochemical Properties*. In: Proceedings of the International Conference on Discovery Science. Springer, Berlin, Heidelberg, pp. 66–79.

[3] Cortez, P.; Cerdeira, A.; Almeida, F.; Matos, T.; Reis, J. (2009). *Wine Quality*. UCI Machine Learning Repository. Disponível em: `https://doi.org/10.24432/C56S3T`.

[4] ScienceDirect. (s.d.). *Wine Quality*. Food Science Topics. Disponível em: `https://www.sciencedirect.com/topics/food-science/wine-quality`.

[5] Divvino. (2024). *Como Saber Se O Vinho é De Boa Qualidade?*. Blog Divvino. Disponível em: `https://www.divvino.com.br/blog/vinho-de-boa-qualidade/`.